

BIBLIOTECHE FANTASMA

Analisi, integrazione e modellazione semantica delle biblioteche italiane non pienamente operative

Progetto universitario di Open Data Management

Anno accademico 2025/2026 – versione finale 10 settembre 2026

Sommario

Il progetto sviluppa una pipeline completa di Open Data Management a partire da dati reali dell’Anagrafe delle Biblioteche Italiane (ICCU) e della popolazione residente ISTAT POSAS 2019/2025. La pipeline comprende selezione e verifica delle fonti, cleaning, armonizzazione territoriale, integrazione, metadati, modellazione ontologica con riuso di Cultural-ON, generazione RDF, validazione SHACL, interlinking, interrogazione SPARQL, analisi statistica e data visualization. Il master ICCU contiene 19.611 record; il perimetro analitico delle biblioteche problematiche comprende 2.497 casi su 18.956 biblioteche, pari al 13,17%. La relazione tra variazione demografica comunale 2019–2025 e quota di biblioteche problematiche è debole nel campione completo (Pearson $r = -0,106$, Spearman $\rho = -0,067$, $N = 6.659$) e non risulta robusta restringendo l’analisi ai comuni con più di una biblioteca. La rete delle confluenze comprende 1.412 archi validati. La pipeline genera collegamenti verso ICCU per 19.611 biblioteche e verso Linked ISPRa per 7.893 dei 7.896 comuni della geografia analitica. I risultati vengono interpretati in modo conservativo: i missing non sono trattati come zeri, la correlazione non è causalità, la copertura dei collegamenti esterni è distinta dalla loro dereferenziazione individuale e “Biblioteche Fantasma” è un’etichetta narrativa, non una categoria ufficiale ICCU.

Indice

1	Introduzione	4
1.1	Contesto	4
1.2	Motivazione	4
1.3	Obiettivi	4
1.4	Research Questions	4
1.5	Workflow	5
2	Selezione dei dataset	5
2.1	ICCU	5
2.2	ISTAT 2019	5
2.3	ISTAT 2025	5
2.4	Cultural-ON	5
2.5	Verifica delle fonti	5
2.6	Licenze	5
2.7	Compatibilità	6

3	Analisi preliminare	6
3.1	Data inventory	6
3.2	Data profiling	6
3.3	Stati ICCU	6
3.4	Problemi qualitativi	7
4	Elaborazione	7
4.1	Cleaning	7
4.2	Missing values	7
4.3	Normalizzazione	7
4.4	Coordinate	7
4.5	Parsing confluenze	7
4.6	XML e relazioni 1:N	7
5	Integrazione e arricchimento	8
5.1	Join ICCU	8
5.2	ISTAT	8
5.3	Variazioni amministrative	8
5.4	Indicatori demografici	8
5.5	Dataset strutturato in formato aperto	8
5.6	Qualità dei join	8
6	Metadati	9
6.1	Frictionless	9
6.2	DCAT	9
6.3	Provenance	9
6.4	Licenza derivata	9
7	Modellazione semantica	9
7.1	Competency Questions	9
7.2	Vocabolari	9
7.3	Cultural-ON	9
7.4	Classi	10
7.5	Object Properties	10
7.6	Datatype Properties	10
7.7	Stati e SKOS	10
7.8	Modellazione temporale	10
8	URI Policy	10
9	RDF	10

9.1 Mapping	10
9.2 RDFLib	10
9.3 Turtle	11
9.4 JSON-LD	11
9.5 Validazione	11
9.6 SHACL	11
9.7 Statistiche del grafo	11
10 Linked Open Data	11
10.1 Strategia	11
10.2 Biblioteche	11
10.3 Comuni	12
10.4 sameAs e collegamenti informativi	12
10.5 Coverage	12
10.6 5-star assessment	12
11 SPARQL e triplestore embedded	12
11.1 Triplestore	12
11.2 Query	12
11.3 Risultati	13
12 Analisi	13
12.1 Statistiche descrittive	13
12.2 Territorio – RQ1	13
12.3 Stati – RQ2	13
12.4 Tipologie – RQ3	13
12.5 Demografia – RQ4	14
12.6 Patrimonio – RQ5	14
12.7 Fondi speciali – RQ5	15
12.8 Confluenze – RQ7	15
12.9 Quota 65+ – RQ8	15
13 Data Visualization	15
14 Problemi e decisioni progettuali	18
15 Limiti	19
16 Conclusioni	20
17 Fonti e riferimenti	20

1 Introduzione

1.1 Contesto

Gli Open Data non consistono soltanto nella disponibilità di file scaricabili: richiedono qualità, licenze chiare, formati aperti, metadati, identificatori, interoperabilità e, ai livelli più avanzati, collegamenti verso risorse esterne. Il corso di Open Data Management affronta esplicitamente questo percorso, includendo RDF, RDFS/OWL, triplestore e SPARQL. Il modello a cinque stelle fornisce una sintesi progressiva: dalla pubblicazione con licenza aperta fino ai Linked Open Data collegati al Web of Data [1, 3].

1.2 Motivazione

Il dominio bibliotecario è adatto a un progetto di integrazione perché combina un registro nazionale, identificatori istituzionali, coordinate, classificazioni, patrimonio, fondi speciali e dati territoriali. Lo snapshot ICCU registra inoltre stati eterogenei: cessazione, chiusura temporanea, inagibilità, sospensione per sisma, confluenza e altri casi. Queste etichette non possono essere appiattite in una singola nozione di “biblioteca chiusa”.

Biblioteche Fantasma è quindi una cornice narrativa per studiare le biblioteche che, nello snapshot, presentano condizioni di non piena operatività o trasformazioni particolari. Non è un termine ICCU e non viene introdotto come classe ontologica ufficiale.

1.3 Obiettivi

Gli obiettivi sono: (i) documentare una pipeline riproducibile di selezione, cleaning, integrazione e pubblicazione; (ii) costruire un dataset analitico comunale; (iii) modellare il dominio in RDF riusando vocabolari esistenti; (iv) collegare biblioteche e comuni a risorse esterne; (v) rispondere con dati reali a domande territoriali, demografiche, patrimoniali e di rete; (vi) produrre visualizzazioni leggibili e una data story metodologicamente prudente.

1.4 Research Questions

- RQ1. Dove sono distribuite le biblioteche caratterizzate da stati di non piena operatività?
- RQ2. Quali stati sono più frequenti e come variano tra regioni, province e comuni?
- RQ3. Quali tipologie funzionali/amministrative sono maggiormente associate ai diversi stati?
- RQ4. Esiste un’associazione tra variazione demografica comunale 2019–2025 e quota di biblioteche con cessazione o interruzione del servizio?
- RQ5. Quale patrimonio e quali fondi speciali risultano documentati presso biblioteche non pienamente operative?
- RQ6. Quale copertura ha raggiunto l’interlinking verso risorse Linked Open Data esterne?
- RQ7. Quale struttura presenta la rete delle biblioteche confluite?
- RQ8. Quale relazione secondaria emerge tra quota di popolazione 65+ e biblioteche problematiche?

1.5 Workflow

Il workflow complessivo segue la sequenza: selezione e verifica giuridica delle fonti; profiling; cleaning; integrazione ICCU; elaborazione POSAS; armonizzazione amministrativa; produzione dei dataset strutturati; metadati; ontologia; URI policy; RDF; SHACL; interlinking; SPARQL; analisi quantitativa; visualizzazione; interpretazione e verifica della riproducibilità. La pipeline è implementata mediante script eseguibili a partire dagli archivi RAW conservati nel repository.

2 Selezione dei dataset

2.1 ICCU

La fonte primaria è l'Anagrafe delle Biblioteche Italiane dell'ICCU [4]. Lo snapshot usato dal progetto è datato 8 settembre 2026 alle 14:11:15 e contiene 19.611 record nel master. Gli ISIL sono completi e unici. Il pacchetto originale comprendeva dati di territorio, tipologie, patrimonio, fondi speciali e contatti; il formato di scambio è documentato da ICCU [5].

2.2 ISTAT 2019

POSAS 2019 fornisce la popolazione residente al 1 gennaio 2019 articolata per età, sesso e stato civile [8]. Il dataset utilizzato comprende 7.954 comuni. Il valore di età 999 è stato usato come totale solo dopo un controllo empirico di coerenza con la somma delle età 0–100.

2.3 ISTAT 2025

POSAS 2025 è la geografia canonica dell'analisi e contiene 7.896 comuni. Le popolazioni 2025 permettono inoltre di calcolare indicatori per 100.000 abitanti e le quote 65+.

2.4 Cultural-ON

Cultural-ON, versione 2.0, è riutilizzato per classi e proprietà del dominio culturale [9]. Sono stati verificati direttamente nel file locale, tra gli altri, `cis:Library`, `cis:Site`, `cis:Collection`, `cis:hasSite`, `cis:hasCollection` e `cis:hasISTATCode`.

2.5 Verifica delle fonti

Le fonti sono registrate in `metadata/source_manifest.csv`, con URL ufficiali, data di acquisizione, licenza, ruolo nel progetto, percorso locale e hash SHA-256. Gli archivi RAW originali ICCU e ISTAT sono conservati in `data/raw/`, permettendo di verificare l'integrità delle sorgenti e di riprodurre la pipeline senza ricaricare snapshot differenti.

2.6 Licenze

Gli Open Data ICCU sono dichiarati CC0 1.0 [6]; i dati ISTAT sono riutilizzati secondo CC BY 4.0 [7]; Cultural-ON è CC BY 3.0 IT. Il dataset tabellare derivato è distribuito CC BY 4.0, con attribuzione a ISTAT e citazione ICCU.

2.7 Compatibilità

CC0 e CC BY sono compatibili con una distribuzione derivata CC BY 4.0, fermo restando che la licenza del progetto non sostituisce le licenze dei materiali di terze parti separati. Le condizioni sono documentate in `metadata/licenses.md`.

3 Analisi preliminare

3.1 Data inventory

La Tabella 1 riassume le principali tabelle processate prodotte dalla pipeline.

Risorsa	Righe	Unità	Chiave/cardin.
library.csv	19.611	record ICCU	ISIL, 1:1
library_status.csv	19.611	stato normalizzato	ISIL, 1:1
library_type.csv	13.715	tipologia	ISIL, 1:1 sul sottoinsieme
library_holdings.csv	93.512	materiale	1:N
special_collection.csv	9.737	fondo speciale	1:N
library_mergers.csv	1.502	confluenza	source ISIL
analysis_municipality.csv	7.896	comune 2025	codice ISTAT

Tabella 1: Inventory dei processed data utilizzati.

3.2 Data profiling

Gli ISIL sono 19.611, tutti presenti e unici. Le coordinate pulite complete sono 19.524. Il dataset comunale comprende 7.896 comuni, 6.660 dei quali hanno almeno una biblioteca nel denominatore analitico. La popolazione totale 2025 nei processed data è 58.943.464 abitanti.

3.3 Stati ICCU

Gli 11 stati normalizzati e le frequenze sono riportati nella Tabella 2.

Stato normalizzato	Conteggio	% record
Nessuno stato speciale registrato	13.200	67,31
Biblioteca non più esistente	1.827	9,32
Biblioteca non censita	1.723	8,79
Biblioteca confluita	1.502	7,66
Altro istituto collegato ICCU	655	3,34
Temporaneamente chiusa	619	3,16
In via di allestimento	34	0,17
Deposito senza punto di servizio	33	0,17
Servizi sospesi causa sisma	12	0,06
Inagibile	4	0,02
Riapertura/agibilità parziale	2	0,01

Tabella 2: Distribuzione nazionale degli stati. Il denominatore è 19.611 record ICCU.

La categoria “nessuno stato speciale registrato” deriva da un valore sorgente nullo e non viene equiparata a “biblioteca aperta”. Il perimetro principale include cessazione, chiusura temporanea, inagibilità, sospensione per sisma, riapertura parziale e deposito senza punto di servizio: 2.497 record.

3.4 Problemi qualitativi

I principali problemi sono la copertura non uniforme dei dataset secondari, coordinate originarie (0,0), tre coordinate fuori dal bounding box italiano, 90 confluenze senza target ISIL parseabile, un self-loop, due comuni non comparabili nel 2019 e la semantica incompleta dei missing. Questi elementi sono preservati o marcati, non “corretti” arbitrariamente.

4 Elaborazione

4.1 Cleaning

Il cleaning ha conservato le stringhe originali e creato colonne normalizzate; ha trattato (0,0) come coordinata mancante nelle colonne pulite; ha convertito le date in ISO quando possibile; ha preservato gli outlier con flag e non ha effettuato geocoding. Il file `reports/cleaning_log.csv` documenta le principali decisioni di cleaning e le relative evidenze verificabili.

4.2 Missing values

La regola generale è *missing* $\neq$ *zero*. Questa distinzione è centrale per patrimonio, fondi speciali e stati. In particolare, una quantità mancante non viene sommata come zero e l'assenza di un record di fondo speciale non è trasformata in un'asserzione di assenza del fondo.

4.3 Normalizzazione

Gli stati sono normalizzati in 11 concetti; i nomi e gli indirizzi hanno versioni originali e normalizzate; i codici ISIL e ISTAT sono trattati come stringhe, preservando gli zeri iniziali.

4.4 Coordinate

Sono disponibili 19.524 coppie di coordinate pulite. La mappa finale riusa queste coordinate e non esegue geocoding esterno. Questo evita di introdurre errori o uno snapshot geografico non controllato.

4.5 Parsing confluenze

Dei 1.502 record con stato di confluenza, 1.412 hanno target ISIL parseato ed esistente nello snapshot. I 90 casi senza target valido non generano archi. È preservato il self-loop IT-SS0267 -> IT-SS0267.

4.6 XML e relazioni 1:N

Patrimonio, fondi speciali e contatti derivano da strutture 1:N. La pipeline non appiattisce queste tabelle nel master, evitando duplicazioni artificiali delle biblioteche e consentendo aggregazioni specifiche per RQ.

5 Integrazione e arricchimento

5.1 Join ICCU

Il join del master ICCU verso la geografia ISTAT 2025 tramite codice ISTAT ha copertura 100%. Il master `library.csv` contiene la tipologia funzionale e amministrativa per tutti i 19.611 record; la tabella secondaria `library_type.csv` copre invece 13.715 biblioteche. Poiché la mancata copertura di quest'ultima è fortemente associata allo stato della biblioteca, RQ3 e il knowledge graph utilizzano le tipologie presenti nel master, mentre la tabella secondaria viene mantenuta come fonte di dettaglio e controllo. Le altre coperture secondarie sono: patrimonio 13.715 biblioteche, contatti 13.630 e fondi speciali 2.449.

5.2 ISTAT

Il dataset comunale integra popolazione 2019/2025, variazione assoluta e percentuale, fasce 0–14, 15–64 e 65+, e quote over 65.

5.3 Variazioni amministrative

La geografia canonica è il 2025. Il crosswalk contiene 7.955 relazioni da predecessori verso 7.896 comuni correnti. Trapani e Misiliscemi sono marcati non comparabili perché lo split territoriale del 2021 non è ricostruibile con i soli dati POSAS comunali.

5.4 Indicatori demografici

Per un comune i la variazione percentuale è

$$\Delta_i = \frac{P_{2025,i} - P_{2019,i}}{P_{2019,i}} \times 100.$$

La quota problematica è

$$q_i = \frac{B_i^{\text{problematiche}}}{B_i^{\text{totali}}},$$

definita solo quando $B_i^{\text{totali}} > 0$. Gli indicatori per 100.000 abitanti usano la popolazione 2025.

5.5 Dataset strutturato in formato aperto

I 10 dataset processati sono disponibili in CSV UTF-8, formato strutturato, machine-readable e non proprietario, con licenza e metadati. Dal punto di vista tecnico soddisfano quindi i requisiti di struttura e formato aperto associati al livello 3-star. La classificazione completa del modello a cinque stelle richiede tuttavia anche la pubblicazione sul Web, trattata separatamente nella valutazione del progetto. È presente un Data Package Frictionless in `metadata/datapackage.json`.

5.6 Qualità dei join

Il master biblioteca–comune raggiunge il 100%. I due comuni non comparabili sono esclusi dalle correlazioni temporali primarie. Nessun fuzzy matching è usato come metodo principale di integrazione.

6 Metadati

6.1 Frictionless

`metadata/datapackage.json` descrive le 10 risorse CSV, i campi, i tipi, le chiavi primarie e le relazioni di foreign key applicabili, oltre ai formati e agli hash SHA-256 delle distribuzioni finali.

6.2 DCAT

DCAT definisce Dataset e Distribution per l'interoperabilità dei cataloghi [13]; DCAT-AP ne specifica il profilo europeo [2]. Il progetto include `metadata/dcat.ttl`, una descrizione RDF/DCAT locale del dataset e delle relative distribuzioni. Il repository non dichiara una conformità operativa completa a DCAT-AP_IT: le URL di accesso e download sono URI locali `file:` e il namespace di progetto utilizza il dominio di sviluppo `.invalid`. Una pubblicazione reale richiederebbe URI HTTP(S) pubbliche e una validazione rispetto al profilo applicabile.

6.3 Provenance

La provenance è modellata in PROV-O [10] e documenta la derivazione dalle fonti ICCU/ISTAT e le attività principali della pipeline.

6.4 Licenza derivata

Il dataset derivato è CC BY 4.0; la licenza non modifica quella di Cultural-ON né le condizioni specifiche delle fonti terze.

7 Modellazione semantica

7.1 Competency Questions

Nove competency questions guidano la modellazione: stato per regione, inagibilità con fondi speciali, comune di una biblioteca, destinazione delle confluenze, demografia e stato, materiali, link esterni, aggregazione regionale e comuni con perdita demografica.

7.2 Vocabolari

Il criterio è *reuse > extend > create*. Cultural-ON copre le biblioteche, le sedi e le collezioni; SKOS gli stati; PROV-O le osservazioni; GeoSPARQL le geometrie; LOCN gli indirizzi; DCAT/DCTERMS i metadati.

7.3 Cultural-ON

`bf:Municipality` estende `cis:GovernamentalAdministrativeArea`; `bf:SpecialCollection` estende `cis:Collection`. Non viene creata una proprietà locale di localizzazione quando il percorso Cultural-ON già disponibile è sufficiente.

7.4 Classi

Le principali classi locali sono `Municipality`, `LibraryStatusObservation`, `DemographicObservation`, `HoldingObservation` e `SpecialCollection`. Le biblioteche usano direttamente `cis:Library`.

7.5 Object Properties

Le proprietà locali includono `bf:hasStatusObservation`, `bf:hasStatus`, `bf:observedLibrary`, `bf:observedMunicipality`, `bf:hasHoldingObservation` e `bf:mergedInto`.

7.6 Datatype Properties

Sono rappresentati data di osservazione, popolazioni, variazione percentuale, quota 65+, quantità del patrimonio, codici, note di accessibilità e attributi amministrativi.

7.7 Stati e SKOS

Gli 11 stati sono concetti SKOS anziché classi OWL: questa scelta evita di trasformare categorie amministrative eterogenee in tipi ontologici di biblioteca.

7.8 Modellazione temporale

Lo stato è osservato alla data dello snapshot e non viene trattato come proprietà atemporale. Il pattern è `Library -> StatusObservation -> StatusConcept`. Non sono inventate date di inizio/fine.

8 URI Policy

Il namespace di sviluppo è `https://biblioteche-fantasma.invalid/`. I pattern includono `/resource/library/{ISIL}`, `/resource/municipality/{ISTAT_CODE}` e risorse per osservazioni e fondi. L'uso di `.invalid` è deliberato: segnala che le URI non sono dereferenzabili e impedisce di simulare una pubblicazione Web inesistente.

9 RDF

9.1 Mapping

Il mapping RDF usa `library`, `status`, `municipality`, `analysis`, `type`, `previous names`, `holdings`, `special collections` e `mergers`. Le relazioni 1:N sono preservate attraverso risorse dedicate.

9.2 RDFLib

La generazione è implementata in Python/RDFLib mediante `scripts/generate_rdf.py` ed è riproducibile a partire dai dataset processati prodotti dalla pipeline. L'interlinking è generato separatamente da `scripts/generate_links.py`.

9.3 Turtle

`rdf/data.ttl` e `rdf/links.ttl` sono serializzati in N-Triples rigoroso, sottoinsieme valido di Turtle, coerente con RDF 1.1 [11].

9.4 JSON-LD

Il progetto non produce una materializzazione `data.jsonld`; RDF è disponibile nelle serializzazioni utilizzate dalla pipeline, principalmente Turtle/N-Triples.

9.5 Validazione

La validazione strutturale del knowledge graph è PASS, con zero URI malformate, zero predicati o classi locali non definiti, zero risorse locali dangling e zero duplicati serializzati.

9.6 SHACL

Le shapes SHACL sono definite in `shacl/shapes.ttl` e fanno riferimento allo standard SHACL [12]. La validazione è eseguita con `pySHACL 0.40.1` sull'intero knowledge graph caricato nello store locale PyOxigraph. L'esecuzione ha restituito **Conforms: YES**, con 0 violazioni, 0 warning e 0 risultati informativi.

9.7 Statistiche del grafo

Artefatto	Triple
<code>rdf/data.ttl</code>	1.628.669
<code>rdf/links.ttl</code>	27.504
<code>rdf/metadata.ttl</code>	39
<code>ontology/ontology.ttl</code>	195
Totale esplicito importabile	1.656.407

Tabella 3: Conteggio delle triple del knowledge graph.

10 Linked Open Data

10.1 Strategia

L'interlinking evita fuzzy matching quando sono disponibili identificatori ufficiali. La forza semantica del predicato dipende dalla natura della risorsa target.

10.2 Biblioteche

La pipeline genera per tutte le 19.611 biblioteche un collegamento al permalink ufficiale dell'Anagrafe ICCU costruito deterministicamente dall'ISIL, senza fuzzy matching.

10.3 Comuni

Per i comuni la pipeline genera URI verso il dataset Linked ISPRA utilizzando il codice ISTAT a sei cifre. Sono prodotti 7.893 collegamenti su 7.896 comuni; i tre casi esclusi corrispondono a unità amministrative soppresse nel 2026 rispetto alla geografia analitica 2025. La relazione utilizzata è `owl:sameAs` quando l'identificatore rappresenta la stessa unità amministrativa.

10.4 sameAs e collegamenti informativi

La distinzione tra `owl:sameAs` e `rdfs:seeAlso` è metodologica: la prima afferma identità, la seconda un collegamento informativo. Evitare un `sameAs` eccessivo riduce errori semantici.

10.5 Coverage

Entità	Totale	Collegamenti	Coverage
Biblioteche verso ICCU	19.611	19.611	100,0000%
Comuni verso Linked ISPRA	7.896	7.893	99,9620%

Tabella 4: RQ6: copertura di generazione dei collegamenti verso le risorse esterne.

I tre non-match comunali sono Lirio, Castegnaro e Nanto, coerenti con variazioni amministrative intervenute nel 2026 rispetto alla geografia analitica 2025. La percentuale misura la copertura di generazione dei collegamenti secondo la URI policy documentata. Lo schema delle URI Linked ISPRA è stato verificato su risorse reali, ma la pipeline offline non dereferenzia individualmente tutti i 7.893 target esterni.

10.6 5-star assessment

Il progetto contiene RDF con URI e link esterni, ma non è pubblicato con URI dereferenzabili: per questo è corretto descriverlo come *tecnicamente predisposto* al 5-star e non come una pubblicazione 5-star operativa sul Web.

11 SPARQL e triplestore embedded

11.1 Triplestore

Per l'esecuzione delle competency questions è stato utilizzato PyOxigraph, uno store RDF embedded richiamato direttamente da Python e persistito localmente su disco. Questa soluzione consente di interrogare il knowledge graph con SPARQL senza dipendere da un triplestore server esterno e rende l'esecuzione riproducibile direttamente dall'ambiente del repository. Sono state caricate 1.656.407 triple esplicite, corrispondenti alla somma di ontologia, dati, interlinking e metadati RDF.

11.2 Query

Le 11 query SPARQL sono state prima validate sintatticamente con RDFLib e successivamente eseguite sullo store PyOxigraph. Tutte le query hanno completato correttamente l'esecuzione; i risultati sono conservati in `sparql/results/` e il relativo report automatico in `reports/sparql_execution_report.md`.

11.3 Risultati

Tutte le 11 query SPARQL sono state eseguite con successo sullo store PyOxigraph e i relativi risultati sono stati salvati in formato CSV. Un risultato con zero righe non viene considerato un errore: la query 03, relativa alle biblioteche inagibili con fondi speciali documentati, restituisce legittimamente un insieme vuoto nello snapshot analizzato. Il report `reports/sparql_execution_report.md` conserva l'esito e il numero di righe restituito da ciascuna query.

12 Analisi

12.1 Statistiche descrittive

Il master ha 19.611 record. Il denominatore `total_libraries` esclude i 655 record “altro istituto collegato ICCU” e vale 18.956. Le biblioteche problematiche sono 2.497, pari al 13,17% delle biblioteche e al 12,73% di tutti i record ICCU. Il tasso nazionale è 4,24 biblioteche problematiche per 100.000 abitanti.

12.2 Territorio – RQ1

La distribuzione geografica è diffusa. In quota regionale, il Molise registra 80 biblioteche problematiche su 183 (43,72%), la Liguria 209 su 657 (31,81%), l'Abruzzo 93 su 419 (22,20%) e l'Umbria 73 su 407 (17,94%). In valore assoluto la Lombardia ha 366 casi, seguita da Emilia-Romagna (221), Liguria e Campania (209 ciascuna), Toscana (184).

A livello comunale, i maggiori conteggi assoluti sono Milano (139 su 624), Roma (117 su 1.165), Genova (90 su 307), Napoli (78 su 461), Torino (63 su 369), Pisa (61 su 166) e Bologna (59 su 329). I conteggi assoluti non devono essere letti come tassi: le città con molti istituti hanno più opportunità di osservare stati particolari.

12.3 Stati – RQ2

La cessazione è lo stato principale nel perimetro problematico: 1.827 casi. Seguono 619 chiusure temporanee, 33 depositi senza punto di servizio, 12 sospensioni per sisma, 4 inagibilità e 2 riaperture/agibilità parziali. Le confluenze (1.502) sono numerose ma non sono conteggiate come cessazioni: rappresentano trasformazioni organizzative.

12.4 Tipologie – RQ3

RQ3 utilizza le tipologie funzionali e amministrative presenti nel master `library.csv`. Dopo l'esclusione dei 655 record classificati come “altro istituto collegato ICCU”, il campione comprende 18.956 biblioteche. La scelta evita il bias di copertura della tabella secondaria `library_type.csv`, che contiene 13.715 biblioteche e omette sistematicamente numerosi record appartenenti ad alcuni stati.

Tra le tipologie funzionali, la categoria `NON SPECIFICATA` presenta 452 biblioteche problematiche su 1.233 (36,66%). Tra le tipologie informative, i tassi più elevati sono: conservazione 78/554 (14,08%), specializzata 630/4.694 (13,42%), istituto di insegnamento superiore 367/2.774 (13,23%), pubblica 903/8.162 (11,06%) e scolastica 65/1.275 (5,10%). La categoria “importante non specializzata” presenta 2 casi su 256 (0,78%), mentre le categorie itinerante e nazionale non presentano casi problematici nel perimetro analizzato.

Considerando tutte le categorie, l'associazione tra tipologia funzionale e appartenenza al perimetro problematico è statisticamente significativa ($\chi^2 = 735,30$, 8 g.d.l., $p < 10^{-150}$) e il Cramér V corretto è 0,196. Per la tipologia amministrativa si osserva $V = 0,193$ ($\chi^2 = 738,12$, 34 g.d.l., $p < 10^{-130}$).

Il risultato è tuttavia sensibile alla categoria NON SPECIFICATA. Escludendola, per la tipologia funzionale si ottiene $N = 17.723$ e Cramér $V = 0,077$; per la tipologia amministrativa $N = 17.844$ e $V = 0,095$. L'associazione residua è quindi debole. Inoltre alcune celle, soprattutto nella classificazione amministrativa, hanno frequenze attese inferiori a 5; i test inferenziali vanno pertanto letti con cautela e insieme alle distribuzioni descrittive. Nel complesso, RQ3 mostra che parte dell'associazione osservata è legata alla non specificazione della tipologia, mentre tra le categorie informative le differenze sono più contenute.

12.5 Demografia – RQ4

L'analisi primaria usa i comuni comparabili con almeno una biblioteca e valori non mancanti: $N = 6.659$. Prima dell'interpretazione sono stati controllati missing e outlier; la regola IQR identifica 115 outlier della variazione demografica, con limiti circa $[-14,55\%, 9,28\%]$.

Sull'intero campione, Pearson $r = -0,1064$ ($p \approx 3,0 \times 10^{-18}$) e Spearman $\rho = -0,0670$ ($p \approx 4,4 \times 10^{-8}$). Escludendo gli outlier IQR, i coefficienti restano dello stesso ordine di grandezza ($r = -0,0956$ e $\rho = -0,0584$).

Una seconda analisi di sensibilità considera il numero di biblioteche presenti nel comune, poiché con denominatori molto piccoli la quota problematica assume valori fortemente discreti. Limitando il campione ai comuni con almeno due biblioteche, Pearson scende a $r = -0,0318$ ($N = 1.712$, $p = 0,188$) e Spearman a $\rho = 0,0094$ ($p = 0,698$). Con almeno tre biblioteche si ottengono $r = -0,0282$ e $\rho = 0,0331$ ($N = 771$); con almeno cinque, $r = 0,0832$ e $\rho = 0,1062$ ($N = 345$); con almeno dieci, $r = 0,0285$ e $\rho = 0,0145$ ($N = 155$). Il segno e l'ampiezza dell'associazione non sono quindi stabili al crescere del denominatore bibliotecario. La correlazione negativa osservata nel campione completo è debole e non è robusta rispetto a questa seconda analisi di sensibilità.

Il confronto tra gruppi mostra che 4.790 comuni hanno perso popolazione, con quota problematica media 12,42%; 1.869 comuni sono stabili/in crescita, con media 8,48%. La mediana è 0 in entrambi i gruppi, riflettendo la forte presenza di comuni senza biblioteche problematiche. Un Mann-Whitney test individua una differenza nelle distribuzioni ($p \approx 1,17 \times 10^{-5}$), ma l'effetto osservato non dimostra causalità e può riflettere dimensione comunale, densità istituzionale, storia amministrativa o altri confondenti.

12.6 Patrimonio – RQ5

La copertura del dataset patrimoniale non è casuale rispetto allo stato ICCU. È nulla per le 1.827 biblioteche non più esistenti, per i 33 depositi senza punto di servizio e, al di fuori del perimetro principale, per le biblioteche confluite e non censite. È invece pari al 98,38% per le biblioteche temporaneamente chiuse e al 100% per inagibilità, sospensione per sisma e riapertura/agibilità parziale. Le 627 biblioteche problematiche con patrimonio documentato appartengono pertanto quasi esclusivamente agli stati di interruzione o parziale operatività. I dati patrimoniali disponibili non costituiscono un campione casuale dell'intero perimetro problematico.

Tra 2.497 biblioteche problematiche, 627 hanno almeno una riga di patrimonio documentata (25,11%), per 2.828 righe. Le quantità sono mancanti in 461 righe; nessuna riga ha zero esplicito; 2.367 hanno quantità positiva. La somma delle sole quantità positive note è 7.500.259 unità, valore che non può essere interpretato come patrimonio complessivo perché la copertura è parziale e alcune categorie sono aggregati come “totale posseduto”.

I materiali più frequentemente documentati per numero di biblioteche sono volumi e opuscoli (627 biblioteche), periodici (292), totale posseduto (261), periodici correnti (145), periodici spenti (97), audiovisivi (89) e manoscritti (73). La tabella analitica separa righe con quantità mancante e positiva.

12.7 Fondi speciali – RQ5

Nel sottoinsieme problematico non compare alcun record in `special_collection.csv`. Tutti i 9.737 record di fondi speciali del dataset appartengono, nello snapshot, a biblioteche classificate come “nessuno stato speciale registrato”. Questo non significa che le biblioteche problematiche non possiedano fondi speciali: indica che il relativo dataset secondario non li documenta nel sottoinsieme. È quindi un risultato di *coverage*, non di assenza reale.

12.8 Confluenze – RQ7

La rete validata ha 1.412 archi, 1.821 nodi, 410 componenti debolmente connesse e una componente maggiore di 40 nodi. Gli archi sono fortemente concentrati su alcuni target: IT-CT0337 ha grado entrante 39, IT-SS0166 34, IT-CA0298 e IT-PV0265 33, IT-FI0215 32. L'unico ciclo è il self-loop già noto.

Geograficamente, le maggiori numerosità di archi in uscita sono in Emilia-Romagna (210), Sicilia (197), Toscana (150), Sardegna (144) e Lombardia (133). La visualizzazione mostra soltanto la componente maggiore per evitare un grafo illeggibile.

12.9 Quota 65+ – RQ8

Come analisi secondaria, la quota over 65 nel 2025 è correlata con `problematic_share` su $N = 6.659$ comuni: Pearson $r = 0,1454$ e Spearman $\rho = 0,1054$. L'associazione è positiva ma debole; è mantenuta come risultato descrittivo e non viene interpretata come spiegazione causale.

13 Data Visualization

Le visualizzazioni sono state selezionate in funzione della domanda: comparison per le regioni, distribution per gli stati, relationship per demografia e struttura per età, geografia per RQ1, rete per RQ7. Sono stati evitati grafici 3D, pie chart con molte categorie e assi troncati ingannevoli.




Figura 1: RQ1: mappa statica delle biblioteche problematiche con coordinate pulite.




Figura 2: RQ1-RQ2: quota regionale con conteggi assoluti annotati.




Figura 3: RQ2: distribuzione degli stati normalizzati.




Figura 4: RQ4: variazione demografica 2019-2025 e quota problematica.





Figura 5: RQ5: copertura documentaria di patrimonio e fondi speciali nel perimetro problematico.

La componente di confluenza più grande ha 40 nodi e converge verso pochi target
 Visualizzata solo la componente debole maggiore per evitare uno spaghetti chart; dimensione nodo $\propto$ grado entrante.



Fonte: elaborazione su snapshot ICCU 08/09/2026 e ISTAT POSAS 2019-2025. La rete completa: 1.412 archi validati, 410 componenti.

Figura 6: RQ7: componente debole maggiore della rete delle confluenze.

La versione interattiva della mappa è [visualizations/library_map.html](#), con clustering e layer per stato. Le figure statiche sono esportate ad alta risoluzione e includono fonte e note metodologiche.

14 Problemi e decisioni progettuali

Il `decisions_log.md` registra le decisioni nel formato problema–evidenza–alternative–decisione–motivazione–conseguenza. Tra le scelte più rilevanti: preservare relazioni 1:N; distinguere stati ICCU;

usare una geografia 2025; non imputare missing; riusare coordinate ICCU senza geocoding; separare analisi tabellare da SPARQL; usare URI `.invalid` finché non esiste un dominio; visualizzare solo la componente maggiore della rete.

Gli output tabellari del progetto sono distribuiti in CSV UTF-8, formato strutturato, machine-readable e non proprietario. La pipeline mantiene separati i RAW originali e i dataset processati e consente di rigenerare gli artefatti derivati mediante gli script documentati nel repository. La disponibilità di una serializzazione Parquet è opzionale e non costituisce un requisito per la riproducibilità del progetto.

I notebook 01–08 documentano le principali componenti della pipeline, dall’inventario e profiling delle sorgenti fino all’analisi quantitativa e alla visualizzazione. Le trasformazioni deterministiche sono implementate negli script della directory `scripts/`; i notebook consentono di ispezionare dati, controlli intermedi e risultati senza sostituire gli script utilizzati per la riproduzione automatica.

15 Limiti

1. Lo snapshot ICCU non rappresenta necessariamente una serie storica completa.
2. Lo stato osservato non fornisce automaticamente data di inizio o fine.
3. “Nessuno stato speciale registrato” non certifica piena operatività.
4. La completezza ICCU varia tra biblioteche e dataset secondari.
5. Patrimonio mancante non equivale a patrimonio inesistente.
6. Fondo speciale non documentato non equivale ad assenza del fondo.
7. La correlazione demografica non dimostra causalità.
8. Fusioni, incorporazioni e scorpori comunali complicano i confronti 2019–2025.
9. URI ed endpoint esterni possono cambiare o diventare indisponibili.
10. “Biblioteche Fantasma” è un’etichetta narrativa e non una categoria ufficiale ICCU.
11. Il denominatore delle quote regionali esclude i 655 record classificati come altri istituti collegati ICCU; usare il totale del registro produrrebbe un indicatore diverso.
12. La tabella secondaria `library_type.csv` copre 13.715 biblioteche e presenta una copertura selettiva rispetto allo stato; per questo RQ3 utilizza le tipologie presenti nel master `library.csv`. La categoria `NON SPECIFICATA` rimane comunque informativamente distinta dalle tipologie effettivamente classificate.
13. La quota problematica comunale è fortemente influenzata da denominatori piccoli: 4.947 dei 6.659 comuni inclusi nell’analisi RQ4 hanno una sola biblioteca. La correlazione negativa osservata nel campione completo si riduce quasi a zero restringendo l’analisi ai comuni con almeno due o tre biblioteche e non è quindi robusta rispetto a questa scelta del denominatore.
14. La somma delle quantità patrimoniali note può includere livelli di aggregazione non omogenei (materiali specifici e “totale posseduto”) e non è un inventario additivo complessivo.
15. La rete delle confluenze deriva dallo stato osservato nello snapshot e non contiene necessariamente tutte le trasformazioni storiche.
16. I collegamenti verso Linked ISPRa sono generati deterministicamente a partire dai codici ISTAT secondo la URI policy documentata; la pipeline offline non dereferenzia individualmente tutti i target esterni.

17. Le URI locali non sono dereferenzabili e impediscono una dichiarazione operativa di 5-star Linked Open Data.
18. Gli archivi RAW ICCU e ISTAT sono conservati nel repository e verificabili mediante gli hash SHA-256 registrati nel source manifest; la riproducibilità resta comunque dipendente dalla disponibilità di un ambiente Python compatibile con le dipendenze dichiarate.

16 Conclusioni

Il progetto dimostra l'intero percorso logico dagli Open Data tabellari a un knowledge graph interlinkato, mantenendo separati dati, semantica e interpretazione. Le 2.497 biblioteche del perimetro problematico rappresentano il 13,17% delle 18.956 biblioteche del denominatore analitico. La distribuzione territoriale è molto eterogenea: le quote più alte sono in Molise e Liguria, mentre i maggiori valori assoluti si osservano nei sistemi bibliotecari più grandi, come Lombardia e grandi città.

RQ3 mostra inoltre l'importanza della qualità e della copertura delle classificazioni: l'associazione tra tipologia e stato appare moderata includendo la categoria **NON SPECIFICATA**, ma diventa debole quando l'analisi è limitata alle tipologie informative.

RQ4 non supporta una narrazione forte secondo cui lo spopolamento “spiega” le biblioteche problematiche. Nel campione completo la relazione è negativa ma debole; inoltre, restringendo l'analisi ai comuni con almeno due o tre biblioteche, la correlazione si riduce quasi a zero e perde significatività statistica. Il risultato non è quindi robusto rispetto alla numerosità del denominatore bibliotecario. Questa evidenza è metodologicamente utile proprio perché impedisce una data story causale o strutturale non supportata.

La rete delle confluenze mostra una struttura frammentata con numerosi piccoli componenti e alcuni hub di destinazione. Sul versante Linked Data, la copertura di generazione dei collegamenti è elevata grazie all'uso di identificatori ufficiali: 100% per le biblioteche e 99,9620% per i comuni. Queste percentuali descrivono i collegamenti prodotti dalla URI policy e non una verifica HTTP individuale di tutti i target esterni. Resta tuttavia un confine netto tra un grafo *predisposto* al Web of Data e una pubblicazione 5-star effettiva: senza dominio pubblico e URI dereferenzabili, il livello massimo non può essere dichiarato operativo.

In termini didattici, il valore del progetto non è la dimensione del grafo ma la tracciabilità tra Research Question, dato, metodo, risultato, visualizzazione, interpretazione e limite. Le scelte conservative sui missing, sugli stati, sulle equivalenze esterne e sulla causalità sono parte integrante della qualità del risultato.

17 Fonti e riferimenti

- [1] Tim Berners-Lee. *5 Star Open Data*. 2010. URL: <https://5stardata.info/>.
- [2] European Commission - SEMIC. *DCAT Application Profile for Data Portals in Europe (DCAT-AP)*. 2026. URL: <https://semiceu.github.io/DCAT-AP/>.
- [3] Tom Heath e Christian Bizer. *Linked Data: Evolving the Web into a Global Data Space*. Morgan & Claypool, 2011. URL: <http://linkeddatabook.com/editions/1.0/>.
- [4] ICCU - Istituto Centrale per il Catalogo Unico. *Anagrafe delle Biblioteche Italiane - Open Data*. Snapshot utilizzato: 8 settembre 2026. 2026. URL: <https://anagrafe.iccu.sbn.it/it/open-data/>.
- [5] ICCU - Istituto Centrale per il Catalogo Unico. *Formato di scambio dell'Anagrafe delle Biblioteche Italiane, versione 1.6*. 2026. URL: <https://anagrafe.iccu.sbn.it/it/informazioni/formato-di-scambio/>.

- [6] ICCU - Istituto Centrale per il Catalogo Unico. *Norme di utilizzo dei dati dell'Anagrafe delle Biblioteche Italiane*. 2026. URL: <https://anagrafe.iccu.sbn.it/it/footer/norme-di-utilizzo-dei-dati/>.
- [7] Istat - Istituto nazionale di statistica. *Open Data e condizioni di riutilizzo*. 2026. URL: <https://www.istat.it/dati/open-data/>.
- [8] Istat - Istituto nazionale di statistica. *Popolazione residente per eta, sesso e stato civile al 1 gennaio (POSAS)*. 2026. URL: <https://demo.istat.it/app/?i=POS>.
- [9] Ministero per i beni e le attivita culturali e CNR-ISTC STLab. *Cultural-ON: Cultural ONtology, versione 2.0*. 2016. URL: <https://dati.beniculturali.it/cultural-ON/ITA.html>.
- [10] World Wide Web Consortium. *PROV-O: The PROV Ontology*. Rapp. tecn. W3C, 2013. URL: <https://www.w3.org/TR/prov-o/>.
- [11] World Wide Web Consortium. *RDF 1.1 Concepts and Abstract Syntax*. Rapp. tecn. W3C, 2014. URL: <https://www.w3.org/TR/rdf11-concepts/>.
- [12] World Wide Web Consortium. *Shapes Constraint Language (SHACL)*. Rapp. tecn. W3C, 2017. URL: <https://www.w3.org/TR/shacl/>.
- [13] World Wide Web Consortium. *Data Catalog Vocabulary (DCAT) - Version 3*. Rapp. tecn. W3C, 2024. URL: <https://www.w3.org/TR/vocab-dcat-3/>.